



Universidade Federal do Estado do Pará
UFPA

Aprendizado de Máquina para Predição de Incidentes de grupos Terroristas

Felipe Rafael Barbosa



Tópicos

- Introdução
- Materiais e Métodos
- Obtenção da base de dados
- Metodologia CRISP-DM
- Análise e pré-processamento dos Dados
- Modelagem
- Resultados

Introdução

Objetivo:


Prever o Grupo que Efetuou o Ataque

Identificar o problema de segurança pública relacionado a ataques terroristas, visando prever o grupo que efetuou o ataque e identificar padrões em grupos terroristas.

Compreender a importância da previsão de ataques para a segurança global.




Materiais e Metodos





Obtenção da base de dados

A base de dados GTD foi obtida a partir de uma extensa coleta de informações públicas de fontes como notícias, reportagens, documentos governamentais e acadêmicos. A coleta e curadoria dos dados são realizadas pelo *National Consortium for the Study of Terrorism and Responses to Terrorism* (START).



Sobre a base de Dados

- Contém informações detalhadas sobre incidentes terroristas desde 1970 – 2020



Quant. Instâncias

- A base de dados contém **209.705** registros de ataques conhecidos e desconhecidos.



Quant. Atributos


- Contém cerca de **135** atributos, entre eles, o tipo de arma, data, grupo, localização, etc.

Planejamento CRISP-DM


	Objetivo		Tarefas
Etapas			
Compreensão do Negócio	Identificar padrões e prever grupo responsável pelo o ataque.	Definir métricas (precisão, recall, etc.) e entender a importância da previsão para a segurança global.	
Entendimento dos Dados	Analisar o conjunto de dados GTD.	Explorar atributos como localização e grupo responsável.	
Preparação dos Dados	Preparar os dados para modelagem.	Limpeza, transformação de atributos e divisão dos dados.	
Modelagem	Desenvolver modelos de machine learning.	Aplicar algoritmos (ex.: Random Forest) e otimizar a performance.	
Avaliação	Avaliar o desempenho dos modelos.	Usar métricas como acurácia, F1-score, e outras.	


Análise



Quantidade de Ataques Terroristas por Ano



Coordenadas de Ataques (2016-2020)









Em dados de ataques terroristas, eventos extremos (como um ataque com muitas mortes ou feridos) podem ser reais e relevantes. Esses valores, apesar de parecerem outliers, podem refletir a realidade e não devem ser removidos ou ajustados.

O número consideravelmente maior de ataques bem-sucedidos em comparação aos suicidas sugere que ataques suicidas representam uma pequena parte dos incidentes gerais, mas sua ocorrência pode estar associada a um impacto mais extremo, o que os torna relevantes para análises futuras.





Preparação dos Dados

Tarefas Realizadas:


Tratamento de Valores Faltantes: Remoção ou imputação de dados ausentes em colunas críticas.

Codificação de Variáveis Categóricas: Conversão de atributos categóricos (ex.: tipo de ataque, grupo terrorista) em valores numéricos usando técnicas como One-Hot Encoding.

Normalização dos Dados: Ajuste dos valores de diferentes atributos para uma escala comum, evitando que um atributo domine o modelo.

Feature Engineering: Criação de novas variáveis relevantes a partir de atributos brutos, como data e localização.

Divisão de Dados: Separação em conjuntos de treino, validação e teste para garantir a eficácia do modelo.



Modelagem

Random Forest

Instâncias Utilizadas = 25000

Split 30% Teste e 70% Treino

Hiperparametros:

- **N° Estimadores** 100
- **Random_state** 42
- **Max_depth** default
- **min_samples_split** default
- **max_features** default

Rede Neural

Instâncias Utilizadas = 25000

Split 30% Teste e 70% Treino

Hiperparametros:


 **Neuronios** na primeira camada 128

 **Neuronios** na segunda camada 64

 **Funções de ativação** relu nas 2 primeiras camadas e softmax no output

 **Épocas** 20

 **validation_split** = 0.2



Resultados

Random Forest

Acurácia: 0.97

Precisão: 0.95

Recall: 0.97

F1-Score: 0.95

Rede Neural

Epoch 1/20					
428/428		10s	20ms/step	- accuracy: 0.3668 - loss: 4.4140 - val_accuracy: 0.4474 - val_loss: 2.6395	
Epoch 2/20					
428/428		10s	23ms/step	- accuracy: 0.4675 - loss: 2.4708 - val_accuracy: 0.6086 - val_loss: 2.1632	
Epoch 3/20					
428/428		8s	18ms/step	- accuracy: 0.5845 - loss: 1.9386 - val_accuracy: 0.6641 - val_loss: 1.7498	
Epoch 4/20					
428/428		10s	24ms/step	- accuracy: 0.6779 - loss: 1.5426 - val_accuracy: 0.6863 - val_loss: 1.5919	
Epoch 5/20					
428/428		20s	23ms/step	- accuracy: 0.7228 - loss: 1.3133 - val_accuracy: 0.7281 - val_loss: 1.4384	
Epoch 6/20					
428/428		8s	18ms/step	- accuracy: 0.7511 - loss: 1.1385 - val_accuracy: 0.7693 - val_loss: 1.3126	
Epoch 7/20					
428/428		12s	21ms/step	- accuracy: 0.7787 - loss: 1.0040 - val_accuracy: 0.7967 - val_loss: 1.1725	
Epoch 8/20					
428/428		10s	21ms/step	- accuracy: 0.8033 - loss: 0.8995 - val_accuracy: 0.8189 - val_loss: 1.1511	
Epoch 9/20					
428/428		11s	25ms/step	- accuracy: 0.8257 - loss: 0.7805 - val_accuracy: 0.8455 - val_loss: 1.0073	
Epoch 10/20					
428/428		8s	20ms/step	- accuracy: 0.8379 - loss: 0.7215 - val_accuracy: 0.8064 - val_loss: 1.1135	
Epoch 11/20					
428/428		10s	23ms/step	- accuracy: 0.8529 - loss: 0.6650 - val_accuracy: 0.8554 - val_loss: 0.9789	
Epoch 12/20					
428/428		8s	18ms/step	- accuracy: 0.8639 - loss: 0.5975 - val_accuracy: 0.8551 - val_loss: 0.9004	
Epoch 13/20					
428/428		7s	16ms/step	- accuracy: 0.8685 - loss: 0.5645 - val_accuracy: 0.8855 - val_loss: 0.8854	
Epoch 14/20					
428/428		6s	13ms/step	- accuracy: 0.8845 - loss: 0.4947 - val_accuracy: 0.8709 - val_loss: 0.8636	
Epoch 15/20					
428/428		8s	18ms/step	- accuracy: 0.8905 - loss: 0.4703 - val_accuracy: 0.8843 - val_loss: 0.8245	
Epoch 16/20					
428/428		6s	13ms/step	- accuracy: 0.8862 - loss: 0.4614 - val_accuracy: 0.8803 - val_loss: 0.8493	
Epoch 17/20					
428/428		12s	16ms/step	- accuracy: 0.8990 - loss: 0.4141 - val_accuracy: 0.8750 - val_loss: 0.8557	
Epoch 18/20					
428/428		6s	14ms/step	- accuracy: 0.9079 - loss: 0.3865 - val_accuracy: 0.8835 - val_loss: 0.8634	
Epoch 19/20					
428/428		8s	18ms/step	- accuracy: 0.9103 - loss: 0.3628 - val_accuracy: 0.8911 - val_loss: 0.8390	
Epoch 20/20					
428/428		6s	13ms/step	- accuracy: 0.9125 - loss: 0.3487 - val_accuracy: 0.8841 - val_loss: 0.8454	

Acurácia: 0.89

Recall: 0.89

Precisão: 0.87

F1-Score: 0.87

Referências

- Times, T. N. Y. (2022). Who are the Taliban, and what do they want? The New York Times.
- Zoli, C., Steinberg, L. J., Grabowski, M., & Hermann, M. (2018). Terrorist critical infrastructures, organizational capacity and security risk. *Safety Science*, 110(March 2017), 121–130.
- Schittino, R. T. (2004). Terrorismo: A violência política como espetáculo. (Dissertação de Mestrado). Pontifícia Universidade Católica do Rio de Janeiro, Rio de Janeiro, Brasil.
- Gaibullov, K., & Sandler, T. (2009). The impact of terrorism and conflicts on growth in Asia. *Economics and Politics*, 21(3), 359–383.
- Ravi, D., Wong, C., Deligianni, F., Berthelot, M., Andreu-Perez, J., Lo, B., & Yang, G.-Z. (2017). Deep learning for health informatics. *IEEE Journal of Biomedical and Health Informatics*, 21(1), 4–21.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12(85), 2825–2830. Disponível em: <https://jmlr.csail.mit.edu/papers/v12/pedregosa1>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45, 5–32.
- Abiodun, O. I., Jantan, A., Omolara, A. E., Dada, K. V., Mohamed, N. A., & Arshad, H. (2018). State-of-the-art in artificial neural network applications: A survey. *Heliyon*, 4(11).
- Fernández, A., Galar, M., & Krawczyk, B. (2018). Learning from imbalanced data sets. Gewerbestrasse, Switzerland: Springer. doi:10.1007/978-3-319-98074-4.